



蔡沐书



年龄：23岁
籍贯：河南省信阳市
电话：15637639558 (微信同号)
性别：男
政治面貌：中共党员
邮箱：2024110423@bupt.cn

教育背景

2024.09 - 至今 北京邮电大学 (211 双一流) 电子科学与技术 (A-) (推免) (硕士)
2020.09 - 2024.06 北京邮电大学 (211 双一流) 应用物理学 (成绩前20%) (学士)

所获荣誉

科研/竞赛方面：作为队长获得2024年“华为杯”全国研究生数学建模大赛一等奖。北京邮电大学2025年研究生创新项目A级立项。

奖学金/荣誉方面：

- 2025年：优秀研究生干部、研究生党员骨干、研究生二等奖学金。
- 2024年：优秀毕业生、研究生一等奖学金。
- 2023年：国家励志奖学金、文体积积极分子、英语六级证书。
- 2022年：国家励志奖学金、文体积积极分子、英语四级证书。
- 2021年：小米奖助学金、文体积积极分子、权益部优秀干部。

论文方面：Yawei Wang, Mushu Cai, Le Yuan, Shaohua Liu, Yancheng Yao.RD-MAF: A Residual-Driven Framework for Multivariate Time-Series Anomaly Detection and Adaptive Hierarchical Forecasting. (ISA JCR Q1/中科院2区TOP 审稿中)

实习经历

2026.05 - 2026.09 美团-核心商业 大模型搜索算法实习生

背景描述：面向美团主站搜索和本地生活的消费医疗垂搜场景，参与大模型检索范式的落地与优化，提升搜索精准度与用户体验。

- 构建商品、商家、类目多源信息联合语义表征，解决同名商品门店混淆问题；设计层级量化语义编码并融入地理位置网格约束，将模型独立编码率提升至 94% (+23pp)。
- 两阶段模型微调与效果验证：基于Qwen-0.6B，设计实现“语义对齐”——“用户行为对齐”的两阶段递进式微调，实现用户查询到目标结果的精准映射；离线评测较传统向量检索指标从提升至 83% (+11pp)，上线后订单量与搜索点击量显著正向增长。
- 设计“历史增强 Teacher—轻量 Student”联合自蒸馏框架：以用户历史下单类目与商圈偏好作为 Teacher 特权信息，通过 CE + KL 联合优化将个性化知识迁移至线上模型，进一步提升召回效果。

2025.12 - 2026.04 知乎 大模型搜索算法实习生

背景描述：参与生成式搜索框架全链路搭建，负责语义表征模型调优、离散语义索引构建与大语言模型指令微调。

- Qwen3-Embedding 模型调优：制定全谱系采样策略，从海量数据库中构建高质量训练集；自主构建正样本聚合度评估体系，围绕训练范式、正负样本配比、输入序列长度等进行多轮对比调优实验，最终实现语义表征正样本聚合度提升9%。
- 离散语义索引构建：承接上游向量表征，构建数据语义索引。从零搭建语义 ID 与码本质量的评估体系，通过实验对比选择最优量化模型，引入查询—文档的后验知识进行监督训练，构建高质量数据语义索引。
- 大语言模型的指令微调：基于前期生成的语义索引，组织训练数据集对模型进行初始化，采用自回归训练范式对 Qwen-4B 模型进行 SFT。离线测试中，关键召回指标从 55% 提升至 61%。

2025.10 - 2025.11 猎聘 大模型算法实习生

背景描述：参与面向公司招聘人员的简历-岗位匹配大模型蒸馏学习任务，负责模型蒸馏的数据生成、处理、优化相关工作，搭建多 agent 架构优化处理思维链数据。

- 利用 DeepSeek-R1 构建思维链蒸馏体系：构建“结论先行 + 分点论证”的思维链结构；从证书、教育背景、城市意向、工作经验等多维度打分形成匹配度软标签，该数据蒸馏后小模型召回率达75.5%，准确率87.3%；
- 设计并落地多 agent 的思维链质量优化框架：基于 Qwen-32B 搭建“评判—修改—验证”多 agent 框架检测并优化思维链中模糊表述、领域知识误判等问题，新数据蒸馏的小模型，在召回率指标上提升3%。

项目经验

ClawCodex | Coding Agent Harness 研发与评测体系建设

项目背景：参与编程智能体研发，优化工具执行与上下文开销；结合 RuVerBench 研究，围绕长执行轨迹的细粒度核验与裁判可靠性开展评测体系建设。

1. **工具与上下文优化**：参与输出压缩及 nano 轻量模式研发，结合原始日志回读、核心工具精简与 Skills 按需加载，将固定上下文载荷由 17K 缩减至 2K tokens；在 27 份真实命令输出回放中，工具输出 token 从 92,989 降至 17,767，减少约 80.9%。

2. **轨迹级评测基准**：参与 Agentic Coding 评测设计，围绕任务完成、计划与状态、工具使用、项目约束建立四维核验体系；覆盖 210 项仓库任务、843 条人工标注核验样本及均 49.4K tokens 的执行轨迹，完成 18 款模型的可靠性评测与分维度误判分析。

3. **评测策略优化**：对 Prompt 风格、单次核验粒度与自投票次数开展对照实验；Qwen3.5-27B 准确率最高提升 11.8%，DeepSeek V4 Flash 最高提升 4.3%，形成模型配置与准确性——采样开销的选择依据。

4. **端到端对照评测**：基于 Harbor 开展 Terminal-Bench 2.1 评测，在 89 项任务、每任务一次运行的设置下，nano 通过 64/89，任务通过率 71.9%，与 Pi 的 70.8% 接近，实验总成本降至 \$1.31，降低约 34.8%。

分布式多智能体协同与算法模型库平台建设

Agent 开发

项目背景：与航空工业光电所合作，建设集“场景仿真、智能体协同、算法调度、任务执行和结果评估”于一体的分布式多智能体平台。基于 BPEL 与 A2A 协议实现任务流编排、Agent 动态调度及异构算法统一接入，实现跨节点协同。

1. **多智能体编排与并发调度**：设计“工作流→Agent 执行 → 算法库”的分层架构；实现多 Workflow、Activity 及同角色 Agent 的三级并发，通过 Slot、Lease 与 Redis 分布式锁控制执行容量，避免多 Commander 重复调度。

2. **动态发现与智能调度**：基于 Nacos 实现 Agent 注册，Commander 侧具有按 Skill 动态发现、选择 Agent 的能力，Agent 侧具有结合任务智能选择算法的能力。

3. **算法模型库建设**：建设算法库，通过 Algorithm Card、输入输出 Schema、golden case、版本及生命周期规范管理40+算法资产，支持 ONNX与Python HTTP双后端、运行时重载、推理缓存及 CLI/HTTP 调用。

4. **高可用与故障恢复**：构建重试、超时、心跳失联监测和熔断机制，支持故障 Agent 自动隔离与同能力实例重指派；结合 Checkpoint 可以实现 Commander 重启后的工作流断点续跑。

基于大数据深度学习的时序预测与装备故障先知系统研制

算法工程师

项目描述：与“宝洁(中国)”公司合作，面向制造行业中生产线设备故障诊断滞后、误报率高的问题，构建设备异常预测与分级预警系统。

1. **时序预测模型研发**：基于 PyTorch 框架构建 LSTM/Transformer 多维时序预测模型，针对工业传感器高维、强相关数据特性优化时间步、预测窗口、多损失函数等核心参数，提升模型对设备运行状态的拟合能力与调优工作；

2. **异常分级算法设计**：创新提出自适应阈值滚动累计异常分级算法，通过迭代优化阈值校准与滚动累积机制，在某生产线历史数据验证中，故障预警准确率达92%（+7pp），误报率降低20%；

3. **工程化落地**：基于 SQL Server 完成端到端实时检测系统部署，实现算法模型在工业场景的稳定运行；

校园经历

2024.09 - 至今

北邮电子院24级第二党支部书记

1. **严格把关支部党员发展**：覆盖积极分子推优、发展对象考察、预备党员转正等关键环节；2025年上半年，所在支部成为全院唯一实现积极分子推优至发展对象全员通过的学生党支部，保障党员队伍“入口严、培养实、转正优”。

2. **严格落实“三会一课”制度**：规范组织党员大会、党支部委员会、党小组会、组织生活会，定期开展专题党课并推动“党员讲党课”活动，确保党内生活制度化、常态化。

3. **策划开展丰富的主题党日活动**：包括但不限于联合邯郸市文旅局党支部开展共建并参观当地红色教育基地、了解当地红色文化；与北航学生支部共建参访京西皮影非遗园，以非遗皮影为载体学习红色故事。

2020.09 - 2024.06

权益部干事/学习委员

院系中：权益部干事

- **主要工作内容**：参与举办校园手绘风筝大赛、手绘面具大赛，趣味运动会，并负责活动推送ppt制作，易拉宝制作。收集、整理院系同学诉求，成功推动宿舍区直饮水机安装落地，切实改善同学生活条件。

班级中：学习委员

- **主要工作内容**：组织考前自习周、学霸笔记分享等学风建设活动，营造互助学习氛围。负责班级学业事务对接，搭建同学与老师之间的沟通桥梁，针对基础薄弱同学开展帮扶，助力班级整体学业提升。

技能特长

- **大模型与 AI 技术**：有丰富的大模型微调、蒸馏、调参实操经验；熟练掌握 Prompt 工程、RAG、Agent 开发；精通 LangChain 框架；具备机器学习、深度学习的项目基础。

• **推理部署与工程化**：熟悉 vLLM 等大模型推理框架，了解模型量化、服务部署、性能评测与瓶颈分析流程，具备 Linux、Docker 环境下的部署与调试经验。

• **模型架构与训练**：熟悉Transformer、MoE等主流大模型架构及工作机制，了解训练数据构建、监督微调与偏好对齐流程。

• **语言**：英语CET4、CET6证书。

兴趣爱好

- **热爱运动**：在校期间积极参加院系羽毛球团体赛及校内交流赛；本科期间在院足球队效力过一段时间。